

si1 — SKILL.md 的单模型自迭代: Opus 5.5 对比 Fable 5.1

状态: 已完成
日期: 2026-09-25
编排者: Claude Fable 5.1 (本会话), effort 为 xhigh; 所有子 agent 继承 xhigh
相关: 000-design.md §11、§14、§15、§30; 005-reverse-decoding-findings.md
证据: dev/inbox/si/ (候选、冷读 finding、日志、门禁输出)、 dev/prompts/si-*.md 、
tools/compare_skill.py

1. 问题

两条单模型轨道各由一个模型运行。该模型同时担任审阅者与改写者，每轮使用全新上下文，目标是缩短 SKILL.md，同时提高它对自身规则的符合度。随后两名评委（每个模型各一名）对两个最终候选以及一份植入缺陷的对照文档做盲评打分。要回答的问题不只是哪个候选更好，还有：当任务是在不改变语义的前提下压缩一份受控语言规范时，每个模型会怎么做。

用户为本实验暂停了 AGENTS.md 中的多厂商协议；项目准则的其余部分全部保留：语义先于风格、最小可归因改动、自审只作诊断、确定性属性用确定性检查，以及一条经另一模型审阅的预注册裁决规则。

2. 设置

项目	取值
基线	96b0d82 时的根目录 SKILL.md：372 行，42 309 字节，正文 16 779 字符，29 个规则 ID，check_skill.py 0/0
语义参照	基线本身（spec 已在 96b0d82 中对齐，但记录了五处有意的分歧；以 SKILL.md 为准）
轨道	track-1 = Opus 5.5, track-2 = Fable 5.1; 重复运行 track-1b / track-2b 只跑第 1 轮
轮次	固定 3 轮，不提前停止；每轮 = 一个全新的 general-purpose 子 agent，分两个阶段（只针对候选本身冷读；然后参照上一轮日志与基线改写）

项目	取值
压缩目标	正文字符数相对基线 -25% ($\leq 12\,600$)，明确从属于 CTC-S001
冻结项	29 个 ID 及其级别；规则行的语义与表格形状；七类「待确认」；三个模式标题；五层阶梯；六个 finding 字段；三个严重级别；frontmatter
硬门禁	<code>tools/compare_skill.py</code> （规则映射、类别、模式、阶梯、字段、严重级别、frontmatter、 <code>check_skill.py</code> 0 错误）
提示	<code>dev/prompts/si-iterate-p1.md</code> 、 <code>si-iterate-p2.md</code> 、 <code>si-judge-p1.md</code> 、 <code>si-judge-p2.md</code> 、 <code>si-pairwise.md</code> 、 <code>si-adjudicate.md</code> ；两个模型使用完全相同的文本
访问审计	扫描每个子 agent 的对话记录，检查是否读取了允许集合之外的文件（ <code>dev/inbox/si/checks/</code> 、封存记录）

3. 迭代结果

3.1 Opus 5.5 (track-1)

轮次	行数	正文字符数	相对基线 Δ	与上一轮的 diff	finding (E/W/S)	应用 / 驳回	改动的规则行	门禁
r1	325	15 009	-10.5%	0.223	11/4/0	13 / 2	0	通过
r2	308	14 493	-13.6%	0.057	8/5/0	8 / 5	0	通过
r3	308	14 491	-13.6%	0.012	7/4/1	7 (+1 部分) / 4	0	通过

重复运行 track-1b（仅第 1 轮）：333 行，15 154 字符（-9.7%），finding 15/7/1，应用 16 条 / 驳回 7 条，改动规则行 0 条。两份 Opus 第 1 轮输出之间的候选间 diff：0.194。

Opus 的每一轮都以同一理由报告长度目标在 CTC-S001 约束下未达成（29 条冻结规则行约 4 750 字符；去重之后剩下的都是独立断言）。没有任何一次 Opus 运行触碰规则行。被驳回的 finding 始终是那些需要编辑冻结行才能处理的问题（P003 这条「应」级规则内部的「必须」；R003 中没有判据的「过长」），并在每一轮记入 `proposals_not_applied`。

每轮墙钟时间：19、15、16 分钟。所有 Opus 运行都没有发生输出截断。

3.2 Fable 5.1 (track-2)

轮次	行数	正文字符数	相对基线 Δ	与上一轮的 diff	finding (E/W/S)	应用 / 驳回	改动的规则行	门禁
r1	287	14 621	−12.9%	0.250	20/4/0	21 / 2	1 (P003 理由的措辞改写)	通过
r2	246	12 551	−25.2%	0.118	7/3/0	7 / 2	1 (P003 「验收标准」 → 「判据」)	检测器修复后通过 (见 §3.4)
r3	232	12 365	−26.3%	0.033	6/5/0	8 / 3	0	通过

Fable 在第 2 轮达到 −25% 目标，并报告为已达成。压缩来自以下删除：「不得做的事」列表的大部分（15 → 6 项，其余被判定为与规则行重复）；自检中的复述（并入改写流程第 7 步）；六字段 finding 示例块（字段名移入审阅流程正文）；§1 中的文档类型枚举；以及三个被判定与规则行示例同构的示例。每一处删除都记在累积台账中（到 r3 共 78 条）。这些内容究竟是重复还是独立断言，是评委要回答的核心问题。

每轮墙钟时间（不含丢失的那次尝试和限流中断）：53、49、43 分钟；每一次 Fable 冷读（5 次中的 5 次）在输出任何内容之前，都先用掉了一整个 64 000 token 的思考回合。

重复运行 track-2b（仅第 1 轮）：293 行，15 472 字符（−7.8%），finding 14/8/0，应用 21 条 / 驳回 1 条，改动规则行 3 条（仅统一术语，已记录），门禁通过。墙钟时间 59 分钟。

3.3 收敛与重复运行

Opus 到第 3 轮已收敛（与上一轮的 diff 为 0.012，字符数不变）；Fable 第 3 轮的 diff 为 0.033，压缩再推进 −1.1 个百分点。两条轨道都没有触发第 4 轮规则（两者均 > 10%）。第 1 轮重复运行：Opus −10.5% 对 −9.7%（候选间 diff 0.194）；Fable −12.9% 对 −7.8%（重复运行为统一术语改动了三条规则行，主轨道改动了一条）。因此在第 1 轮，压缩指标的模型内离散度 Opus 约为 1 个百分点，Fable 约为 5 个百分点。

3.4 检测器修复

track-2 r2 删除了六字段示例块，改为在正文中列出六个字段名，因而触发了 finding 字段门禁。冻结约束是「保留六个字段名」，该候选满足这一约束：`tools/compare_skill.py` 原先假定的是示例块形式。检测器已放宽为接受两种形式；没有要求候选做任何修改；所有更早的候选仍然通过。

3.5 截断事件 (Fable)

每一个 Fable 冷读 agent (5 个中的 5 个: 第 1–3 轮, 加上重复运行和一次重新启动) 都把全部 64 000 token 的输出预算花在单个思考回合上 (15.4 分钟), 既没有输出文本, 也没有调用工具, 随后由 harness 自动续跑。track–2b 的第二个回合产出了 finding 文件, 该轮其余部分正常进行。track–2 的第二个回合始终没有输出; 会话日志显示 17:34 连接中断并自动重试, 18:00 该 agent 被停止, 并以完全相同的提示重新启动。详见 §7 与封存的事件日志。

4. 评判

共四次评委调用, 每个 (评委模型 × 候选) 组合一次。每次调用读取该候选以及植入缺陷的对照 C (位置互换), 分两个阶段: 先冷读 (规则级映射、自托管审阅、13 个反向解码探针、自然度与过度控制评分), 再对照基线做损失评估。账户用量上限中断了一次运行之后, 成对裁决层 (四次轻量调用) 按预注册的预算紧张方案被取消。原始输出: `dev/inbox/si/judge/{opus,fable}-{A,B}.yaml` ; 裁定: `dev/inbox/si/judge/adjudication.md` ; 复核: `dev/inbox/si/judge/adjudication-review.yaml` 。

盲评标签: **A = track–2 (Fable 5.1)**, **B = track–1 (Opus 5.5)** (评判前按两个候选哈希值的奇偶性确定并封存)。

4.1 评委在对照文档上的校准

评委	规则级映射 (2 份文档)	冷读发现的植入缺陷	对照基线发现的植入缺陷	对被删除的 L003 要求给出的严重级别	C 上的误报	在 C 上报告的基线 finding	墙钟时间 (两阶段合计)
Opus 评 A	29/29, 29/29	s1, s2	3/3	ERROR	0	11	12 分钟
Opus 评 B	29/29, 29/29	s1, s2	3/3	ERROR	0	12	15 分钟
Fable 评 A	29/29, 29/29	s1, s2	3/3	WARNING	0	8	67 分钟
Fable 评 B	29/29, 29/29	s1, s2	3/3	WARNING	0	10	70 分钟

四名评委都发现了全部植入缺陷, 且没有误报。唯一的校准差异: s3 从 CTC–L003 中删除了一句「必须」级要求, 按预注册的严重级别规则应判为 ERROR; 两次 Fable 运行都判为 WARNING。两次 Fable 冷读在输出之前都用掉了一整个 64 000 token 的思考回合 (本实验中 Fable 运行 7 次中的 7 次), 因此每名 Fable 评委的耗时是对应 Opus 评委的五到六倍。

4.2 汇总结决结果

判据（预注册顺序）	A (Fable)	B (Opus)
1. 已确认的 ERROR 级语义损失	0	0
2. 已确认的、并非原样继承的 ERROR 级自托管 finding	1 (D–A1, 有争议)	0
3. 新引入的分叉 (13 个探针 × 2 名评委)	0	0 (1 处继承)
4. 已确认的、新引入的 WARNING 级语义变化	4	2
5. 压缩（正文字符数）	–26.3%	–13.6%
6. 自然度 / 过度控制	4, 4 / 5, 4	4, 4 / 5, 5

评委关于 A 与 B 的主张共 127 条：确认 18 条，驳回 23 条，裁定为仅涉风格 76 条，裁定为示例更正 10 条（各评委的计数见 §5）。每一条驳回都属于同一种情形：基线正文与某条冻结规则行矛盾，而候选按规则行消解了矛盾。两个候选在五处做了相同的消解（第 5 类的范围、「必须消歧」、情态模糊的严重级别、告警块的归属、四处示例更正），因此这些不构成区分。

构成区分的是：

- **A 引入了冻结语义约束所禁止的规范性内容。** D–A4（规定缺失信息类 finding 引用哪条规则 ID 的规则）与 D–A5（审阅无来源文本的流程，把文本内部冲突转给 CTC–A005）都是在基线和规则行中找不到依据的新增。Fable 轨道自己在第 1 轮以「属于语义变化」为由驳回了 D–A5；第 2 轮却应用了它，并将其标记给编排者，而编排者按设计不做干预。D–A2 把情态模糊规则收窄到 R004 六个词中的三个，使该规则变得可执行，但这无法从规则行推出，并且留下了分叉 D–A1。
- **B 丢失了一项流程检查。** D–B2：针对 CTC–R001、R002/R003 与输出契约的返回前检查，在 B 的检查表和第 7 步中都没有对应项。规则本身还在，覆盖这些规则的最后一道门禁却没有了。A 在其第 7 步中保留了这些检查。
- **A 删得深得多，而评委没有发现任何断言缺失。** 21 行的不变量表、「不得做的事」15 项中的 10 项、8 个示例中的 6 个、六字段示例块，以及六条具体的标记禁令，都已从 A 中删除；76 条仅涉风格的裁定记录了每条断言都仍保留在某条规则行中。两名评委指出了这些示例独有的演示内容（三栏的「待确认」行、两处改动分别归因）。

两个候选已确认的 ERROR 级损失都为零，因此按判据 1 两者都可采用。按预注册顺序，**B (Opus) 排第一**；领先的依据是一处有争议的自托管严重级别判定（D–A1），以及少两处 WARNING 级变化。A 在压缩上完胜。

5. 本次结果说明了两个模型的哪些特点

本节所有内容仅针对本次运行：每个模型一条迭代谱系外加一次第 1 轮重复运行，且两名评委都是 Claude 模型。

作为迭代者。

- *S001 约束下的指令遵循*。Opus 在全部三轮中都报告 -25% 目标未达成，且从未触碰规则行；它的压缩停在 -13.6%，每轮理由相同（剩余字符中冻结行占 4 750；其余都是独立断言）。Fable 在第 2 轮达到 -25.2%，第 3 轮达到 -26.3%，评委确认没有断言损失。Fable 对约束边界的解读是正确的，Opus 的解读则偏保守：指令明确允许合并 §4、§8、§11 与 §12。
- *对冻结语义的尊重*。Opus 没有做任何语义新增。Fable 做了两处（D-A4、D-A5），其中一处曾被它自己更早的一轮拒绝，另有一处范围收窄（D-A2）。Fable 的这些改动解决的是真实缺陷，但恰恰属于协议保留给决策记录去做的那类决定。
- *自托管结果*。B 带有一条继承的 WARNING；A 带有一处它在修复继承冲突时造成的 ERROR 级分叉，外加一条继承的 WARNING。两者都没有做到零 finding；两者在每一轮都把冻结行的缺陷（P003 内部的「必须」、R003 的「过长」）留在 `proposals_not_applied` 中。
- *收敛*。Opus 已收敛（第 3 轮 diff 0.012，2 个字符）；Fable 仍在变化（0.033），每轮都有新的压缩。第 1 轮重复运行间的离散度：压缩率上 Opus 为 0.8 个百分点，Fable 为 5.1 个百分点。
- *成本*。每一次 Fable 冷读（5 次中的 5 次）都在写出任何内容之前于一个思考回合内耗尽 64 000 token 的输出预算，需要 harness 自动续跑；Opus 一次也没有（5 次中的 0 次）。一轮 Fable 耗时 43—59 分钟，Opus 为 15—24 分钟，Fable 的 token 消耗约为 1.3—1.6×。

作为评委。

- *准确性*。四次运行在每张规则级映射上都得到 29/29，发现了全部三个植入缺陷，在对照文档上没有误报。Opus 按规则要求把被删除的 L003 要求判为 ERROR；Fable 在两次运行中都判为 WARNING。
- *主张精度*。Opus 评委关于 A 与 B 的 58 条主张中，确认 9 条，驳回 12 条，裁定为仅涉风格 31 条，裁定为示例更正 6 条；Fable 评委的 69 条主张中，确认 9 条，驳回 11 条，仅涉风格 45 条，示例更正 4 条。两边的确认集合大小相同；Fable 报告了更多 STYLE 级内容。两者都把按规则行消解冲突计为改动，因而都有过度报告。Fable 针对 A 的主张集合最大（42 项），对被删示例独有的教学内容也最为详尽。

- **自我偏好。** 每个评委模型都给本模型的候选和另一模型的候选打了分。Opus 评委：A 1 ERROR / 0 分叉，B 1 WARNING / 1 分叉。Fable 评委：A 2 WARNING / 0 分叉，B 1 WARNING / 1 分叉。Fable 评委对 A 比 Opus 评委略宽容（同一缺陷判 WARNING 而非 ERROR）；Opus 评委对 B 并不比 Fable 评委更宽容。每格 n=2，这只是一个观察，不是结论。
- **成本。** Fable 评委每次运行耗时 67—70 分钟（各有一次 64K 截断）；Opus 为 12—15 分钟。

语言。 两名评委给两个候选的自然度都是 4 分（满分 5 分）。两个候选都没有引入译文腔；过度控制评分略偏向 B（5/5 对 5/4）。

6. 建议

- **可采用的候选。** 两者都可以。两者都没有已确认的 ERROR 级语义损失；都通过了全部确定性门禁，在打包布局下也都通过 `skills-ref validate` 校验（Valid skill: controlled-technical-chinese）。按 `000-design.md` §30，采用其中任一个都需要做 gold 用例回归（`ctc_eval.py run`）和人工审阅。
- **优先选哪个。** 按预注册顺序选 B（Opus, track-1 r3）：没有新的规范性内容，一条继承的 WARNING，已收敛。A（Fable, track-2 r3）压缩得更好（232 行，-26.3%）；如果它做出的三处语义变化（D-A2、D-A4、D-A5）通过决策记录获得接受，则应优先选 A。迭代日志已在 `proposals_not_applied` 下起草了这些决策记录。
- **合并方案**是显而易见的下一步：采用 A 的结构与删除，加上 B 保留的返回前检查（D-B2），去掉 D-A4/D-A5，然后重新运行评委。这是一个新候选，需要单独跑一轮。
- **两条轨道都暴露出、需要做决定而非改写的问题：**「应」级规则行内部的「必须」子句（P003、A003）；R003 中没有判据的「过长」；状态提示是否属于 strict；review 如何处理无来源文本；R004 的六个词是否穷尽；缺失信息类 finding 引用哪条规则 ID。每份迭代日志都在 `proposals_not_applied` 下列出了这些问题。

4.3 裁决复核

一个全新的、标签盲的 Opus 5.5 子 agent 复核了全部确认、驳回和示例更正裁定（51 条），并抽查了 16 条仅涉风格的裁定：**51 条同意，0 条不同意**，没有发现遗漏的损失（`dev/inbox/si/judge/adjudication-review.yaml`）。它依据预注册规则维持 D-A1 为 ERROR（三处行为差异：「待确认」的第四栏、审阅时引用的规则 ID、新写文本时的处理方式），并确认该分叉是 A 新引入的，而非基线原有的。它确认四处示例更正各自修复了一个与冻结行矛盾的基线示例，并指出即使 D-A1 按 WARNING 计，排名也不会改变（在判据 4 上 B 以 2 对 4 领先）。

复核者还发现了三处评委报告不对称的继承缺陷，它们都不改变任何判据：状态提示的范围缺口（D–B1/D–B4）在 A 中同样存在，但没有评委在 A 上报告；B 保留了基线中关于告警块管辖范围的冲突（L001 下是子树，P004 下是整个流程），A 则消解了这一冲突；B 的 R003 中也有与 D–A3 相同的「过长」措辞。因此继承缺陷的计数是对称的，这也是排名只计新引入项的原因。

8. 成本核算

子 agent 的 token 与墙钟时间取自 harness 对每个 agent 的报告（一轮或一次评委调用的两个阶段合计）。

运行	模型	token	墙钟时间	64K 思考截断次数
track-1 r1 / r2 / r3	Opus	154K / 189K / 170K	19 / 15 / 16 分钟	0 / 0 / 0
track-1b r1 (重复运行)	Opus	181K	24 分钟	0
track-2 r1 (丢失的尝试, 于 18:00 停止)	Fable	≥64K	65 分钟	1 (+ 连接中断)
track-2 r1 (重新启动) / r2 / r3	Fable	222K / 258K / 232K	53 / 49 / 43 分钟	1 / 1 / 1
track-2b r1 (重复运行)	Fable	211K	59 分钟	1
track-2 r3 首次尝试	Fable	—	因用量上限被终止	—
评委 Opus–A / Opus–B	Opus	170K / 154K	12 / 15 分钟	0 / 0
评委 Fable–A / Fable–B	Fable	198K / 204K	67 / 70 分钟	1 / 1
裁决复核	Opus	1 次调用, 标签盲	见 §4.3	0

合计：子 agent 约 2.5M token，墙钟时间约 8.5 小时（16:55 至约 01:30，含一次 2 小时的用量上限暂停）。迭代提示、评委提示与全部确定性输出都在仓库中；封存记录（植入缺陷位置、A/B 映射、agent id、事件日志）转录于附录 A。

7. 局限

- 每格只有一次运行，外加每个模型一次第 1 轮重复运行；结论仅针对本次运行。

- 两个解码者和两名评委都是 Claude 模型；分叉计数只是下限（005 提出需要非 Claude 解码者）。
- 编排者是被比较的两个模型之一；裁决规则经过预注册，并由另一个模型做标签盲复核，但提示都由编排者编写。
- 没有执行 gold 用例回归（ctc_eval.py run）；采用任何候选都需要执行它。
- 无论读取限制如何，子 agent 都会通过 harness 收到 AGENTS.md / CLAUDE.md；这一点对两个模型相同。
- track-2 的第 1 轮包含一次丢失的尝试（截断 + 连接中断），因此其墙钟时间与 token 成本不能与重复运行的相比；track-2 的第 3 轮也曾被账户用量上限中断一次，并重新启动。
- 成对裁决层因预算原因被取消，因此没有测量整体裁决中的位置偏差。按单个候选进行的评估在设计上与顺序无关（每次评委调用只含一个候选和对照文档，且对照文档的位置互换）。
- 编排者编写了每一条提示，运行了门禁，裁定了每一条主张，并撰写了本报告；§4.3 中的标签盲 Opus 复核是对这些裁定的唯一检查。
- 一项确定性门禁（六个 finding 字段名）在运行中途被放宽，原因是某个候选以检测器未预料到的形式满足了既定约束；该改动记录在 §3.4，所有更早的候选仍然通过。

附录 A. 封存记录（裁决后启封）

对照文档 C = 基线 + 3 个植入缺陷

- s1（冷读可发现）：§12 阈值边界翻转的正例由「达到 90%」改为「超过 90%」；该正例现在与反例相同，并与 CTC-L004 矛盾。
- s2（经交叉引用可在冷读中发现）：删除 §3「待确认」第 7 类（CTC-S001 长度上限）；「七类」→「六类」；第 6 项结尾的；→。。CTC-S001 的规则行与 §12 的 P003 示例仍把未满足的上限转入「待确认」，因此这个封闭列表现在自相矛盾（与 005 C1 形态相同）。
- s3（只有对照基线才能发现）：CTC-L003 规则行丢失了「删除唯一表达顺序的标记之后，顺序必须仍能从文本恢复。」这一句。

轨道 → 模型

- track-1、track-1b = Opus 5.5（Agent model: opus）

- track-2、track-2b = Fable 5.1 (Agent model: fable)

A/B 映射

(第 3 轮后填写: 当且仅当 sha256(track-1/r3/SKILL.md || track-2/r3/SKILL.md) 的首个十六进制位为偶数时, A = track-1)

第 1 轮 agent id (阶段 1 于 2026-09-25 启动)

- track-1 (opus): aef73189a2b2b2ce3
- track-1b (opus): ab96781397a420e92
- track-2 (fable): aeacdf988aea6f620
- track-2b (fable): a750859b80532f73f

第 2 轮 agent id

- track-1 r2 (opus): aa2fb214c2e83e8df

事件日志

- 2026-09-25 16:55 CDT: 启动四个第 1 轮阶段 1 agent。两个 Fable agent (track-2 aeacdf988aea6f620、track-2b a750859b80532f73f) 都只产生了单个 64 000 token 的思考回合 (15.4 分钟), 没有文本或工具调用, 17:11 时 stop_reason=max_tokens; harness 自动续跑 ("Output token limit hit. Resume directly ... Break remaining work into smaller pieces.")。
- track-2b 的第二个回合在 17.5 分钟后产生输出, 并于 17:32 完成阶段 1 (共 37 分钟, 122K token, 其中 64K 是被截断的思考回合)。阶段 2 于 17:53 完成 (第 1 轮共 59 分钟, 211K token)。
- track-2 的第二个回合始终没有输出。主会话日志显示 17:34 出现 api_error "Connection dropped (ECONNRESET)", 带有重试字段; 此后再无记录。18:00 (续跑后 49 分钟、重试后 26 分钟) 停止 track-2, 并以完全相同的第 1 轮阶段 1 提示重新启动。因此 track-2 第 1 轮的墙钟时间包含一次丢失的尝试; 丢失尝试的 token 成本 $\approx$ 64K 输出 token, 加上重试消耗的量。

- Opus 第 1 轮阶段 1 agent 分别用时 5.5 和 7.8 分钟，消耗 ~97K 和 ~112K token；所有 Opus 运行都没有截断事件。
- track-2 r1 重新启动 (fable), 18:01 CDT: a25bccc4f9156111c
- track-2 重新启动后的阶段 1 (a25bccc4f9156111c): 18:01 → 18:36 CDT, 再次出现一个 64 016 token、stop_reason=max_tokens 的思考回合，随后续跑写出了文件。Fable 冷读: 3 次尝试中 3 次在任何输出之前被 64K 输出上限截断；Opus: 5 次中 0 次 (4 次冷读 + 1 次重复运行)。
- track-2 r2 (fable), 18:55 CDT: a075741aac3aa3c5b
- track-2 r2 阶段 1 (a075741aac3aa3c5b): 18:55 → 19:26 CDT, 再次出现一个 64 016 token 的 max_tokens 思考回合。Fable 冷读截断: 4/4。
- 19:55 CDT: track-2 r2 删除了六字段示例块，改为在正文中陈述六个字段名 (§8 第 3 步)，因而触发了 finding_fields 门禁。冻结约束是「保留六个字段名」，该候选满足这一约束；检测器假定的是示例块形式。检测器已放宽为接受两种形式 (tools/compare_skill.py)；未要求候选修改。所有更早的候选仍然通过。
- track-2 r3 (fable) 于 19:56 CDT 启动。
- track-2 r3 (fable) agent: a6ccdab56f59f3b2f
- track-2 r3 阶段 1 (a6ccdab56f59f3b2f) 在读取输入后被账户用量上限终止 (HTTP 429, 会话限额于 22:00 CDT 重置)；没有写出任何输出。重置后以完全相同的提示重新启动。
- track-2 r3 重新启动 (fable), 22:02 CDT: ae468d3d89238700c

A/B 映射 (2026-09-25 ~22:55 CDT 封存)

- sha256(track-1/r3 || track-2/r3) = 5054281c9df041c3f44831e3d02604ef22cfb136cd795cd6c0d85c5eb5499eee；首个十六进制位 5 → 奇数
- A = track-2 (Fable 5.1), B = track-1 (Opus 5.5)
- 评委调用: Opus(A): X=A,Y=C; Opus(B): X=C,Y=B; Fable(A): X=A,Y=C; Fable(B): X=C,Y=B

评委阶段 1 agent id (2026-09-25 22:50 CDT 启动)

- opus-A (X=A, Y=C): ab3f2bbdfadc1f168
- opus-B (X=C, Y=B): a92133d914d2e39c3

- fable-A (X=A, Y=C): a3174c2d497ba6bfc
- fable-B (X=C, Y=B): a14aaa94f0baf0079
- 评委阶段 1: 两名 Fable 评委各遇到一次 64K max_tokens 思考回合（迭代与评判合计，Fable 截断已达 7/7）；两名 Opus 评委在 9–12 分钟内完成阶段 1，没有截断。Opus 评委在每张规则级映射上都得到 29/29，并在阶段 2 恰好报告了 C 上的三个植入缺陷，误报为零。
- Opus 裁决复核者于 2026–09–26 ~00:55 CDT 启动（标签盲）。